

# 1 分类的线性方法

## 1.1 线性拟合与感知器

既然分类的输出是离散值, 它当然也属于连续值. 于是, 我们可以简单地沿用线性回归方法, 即

$$y = g(\mathbf{x}; \mathbf{w}) = w_0 x_0 + \cdots + w_M x_M = \mathbf{w}^t \mathbf{x}$$

回归模型输出的是连续值, 因此需要离散化. 例如, 当输出值为  $\{0, 1\}$  时, 可以使用

$$g(\mathbf{x}) = \begin{cases} 1, & f(\mathbf{x}; \mathbf{w}) \geq \frac{1}{2} \\ 0, & f(\mathbf{x}; \mathbf{w}) < \frac{1}{2} \end{cases}$$

将结果离散化. 然而, 如果出现远离数据聚集处的点, 那么线性回归可能会因为迎合这些点而产生较大偏差. 因此, 我们可以直接用阶跃函数进行拟合, 即

$$y = g(\mathbf{x}; \mathbf{w}) = f(\mathbf{w}^t \mathbf{x}) = H(\mathbf{w}^t \mathbf{x}), \text{ where } H(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

其中  $f(z)$  为激活函数, 对输入的  $z$  进行非线性变换得到结果. 这里采用的激活函数为阶跃函数  $H(z)$ . 直接用上述定义的  $g(\mathbf{x}; \mathbf{w})$  进行拟合 (例如进行最大似然法估计等), 这就是**感知器 (perceptron)** 模型.

**定义 1.1 感知器** 使用阶跃函数  $H(z)$  作为激活函数的线性分类模型, 即

$$y = g(\mathbf{x}; \mathbf{w}) = H(\mathbf{w}^t \mathbf{x})$$

称为**感知器 (perceptron)** 模型.

## 1.2 逻辑回归

### 1.2.1 逻辑回归的模型

感知器模型的激活函数是阶跃函数, 它在  $x = 0$  处不可导, 因此无法使用梯度下降法等涉及导数的方法进行优化. 为了替换成光滑的函数以便优化, 我们可以用 sigmoid 函数  $\sigma(z)$  替换前面的阶跃函数:

$$y = g(\mathbf{x}; \mathbf{w}) = \sigma(\mathbf{w}^t \mathbf{x}), \text{ where } \sigma(z) = \frac{1}{1 + e^{-z}}$$

这就是**逻辑回归 (logistic regression)** 模型.

**定义 1.2 逻辑回归** 使用 sigmoid 函数  $\sigma(z)$  作为激活函数的线性分类模型, 即

$$y = g(\mathbf{x}; \mathbf{w}) = \sigma(\mathbf{w}^t \mathbf{x}), \text{ where } \sigma(z) = \frac{1}{1 + e^{-z}}$$

称为**逻辑回归 (logistic regression)** 模型.

上述函数返回一个  $(0, 1)$  间的连续值. 因此, 我们需要将结果解读为样本属于某一类别的概率.

当  $\sigma(\mathbf{w}^\top \mathbf{x}) > 0.5$  时, 我们预测样本属于类别 1 的概率更大; 否则预测样本属于类别 0 的概率更大. 所预测的两种类别的边界称作**决策面 (Decision Boundary)**, 由下式描述:

$$\mathbf{w}^\top \mathbf{x} = 0$$

这是  $\mathbf{x}$  的空间中的一个线性平面.

### 1.2.2 逻辑回归的求解

与前面一样, 逻辑回归也可以归结为一个概率优化问题, 使用极大似然法即可. 仍然假定数据集为  $\mathcal{D} = \{\mathbf{x}_n, t_n\}_{n=1}^N$ , 我们的目标是最大化概率

$$\max_{\mathbf{w}} P()$$